

LAPORAN UTS
COMPUTER VISION



Oleh:

Maulana Ferdiansyah Eka Putra	(187231111)
Ahmad Mirza Rafiq Azmi	(187231059)
Dezilva Zafiazka Setyano	(187231068)
Thalita Putri Kaylaluna	(187231107)
Datok Radja Mulya	(187231110)

FAKULTAS SAINS DAN TEKNOLOGI
S1 - SISTEM INFORMASI
UNIVERSITAS AIRLANGGA
2026

INISIASI DATASET

Dataset yang digunakan:

<https://www.kaggle.com/datasets/soumikrakshit/lol-dataset>

1. Import Library & Unduh Dataset

```
import os, glob, random, time, shutil
import numpy as np
import cv2
import pandas as pd
import matplotlib.pyplot as plt
import kagglehub

SEED = 12
N_IMAGES = 25
IMG_SIZE = (600, 400)

random.seed(SEED)
np.random.seed(SEED)

dataset_path =
kagglehub.dataset_download("soumikrakshit/lol-dataset")
print("Dataset ada di:", dataset_path)
```

Output:

```
Using Colab cache for faster access to the 'lol-dataset' dataset.
Dataset ada di: /kaggle/input/lol-dataset
```

Output menunjukkan dataset LOL berhasil diambil dari cache Colab dan tersimpan di /kaggle/input/lol-dataset. Pesan “Using Colab cache” berarti dataset sudah pernah diunduh, sehingga prosesnya lebih cepat. Variabel SEED = 12 juga dipasang di sini agar pengambilan sampel acak bisa direproduksi dengan hasil yang sama setiap kali notebook dijalankan.

2. Ambil Subset 25 Citra

```
all_low = sorted(glob.glob(os.path.join(dataset_path, "**", "our485",
"low", "*.png"), recursive=True))
print("Total citra low-light:", len(all_low))

random.seed(SEED)
subset = random.sample(all_low, N_IMAGES)

paths = subset
names = [os.path.basename(p) for p in paths]
images = [cv2.resize(cv2.imread(p), IMG_SIZE,
interpolation=cv2.INTER_AREA) for p in paths]

print("Jumlah citra :", len(images))
print("Shape          :", images[0].shape)
print("Dtype          :", images[0].dtype)
print("Contoh nama   :", names[:3])
```

Output:

```
Total citra low-light: 485
Jumlah citra : 25
Shape       : (400, 600, 3)
Dtype       : uint8
Contoh nama : ['551.png', '261.png', '649.png']
```

Dataset memiliki 485 citra low-light pada folder our485/low, dan 25 di antaranya dipilih secara acak. Setiap citra di-resize menjadi 600×400 piksel, sehingga shape-nya (400, 600, 3): tinggi 400, lebar 600, dan 3 kanal warna BGR. Tipe data uint8 berarti nilai piksel berada pada rentang 0-255. Nama file contoh (551.png, 261.png, 649.png) menandakan sampel benar-benar acak, bukan berurutan.

GRAYSCALE & ENHANCEMENT

1. Konversi Semua Citra ke Grayscale

```
gray_images = [cv2.cvtColor(img, cv2.COLOR_BGR2GRAY) for img in
images]

print("Jumlah citra grayscale:", len(gray_images))
print("Shape citra grayscale :", gray_images[0].shape)
```

Output:

```
Jumlah citra grayscale: 25
Shape citra grayscale : (400, 600)
```

Seluruh 25 citra berhasil diubah ke grayscale. Shape berubah dari (400, 600, 3) menjadi (400, 600) karena tiga kanal warna digabung menjadi satu kanal intensitas. Grayscale diperlukan karena SIFT dan ORB bekerja pada informasi intensitas, bukan warna, dan semua metode enhancement berikutnya juga memerlukan input satu kanal.

2. Implementasi 3 Metode Enhancement

```
# A. Histogram Equalization (HE)
he_images = [cv2.equalizeHist(gray) for gray in gray_images]

# B. Contrast Stretching
def contrast_stretching(img):
    # Formula: (I - Min) * (255 / (Max - Min))
    min_val = np.min(img)
    max_val = np.max(img)
    if max_val - min_val == 0:
        return img.copy()
    stretched = (img - min_val) * (255.0 / (max_val - min_val))
    return stretched.astype(np.uint8)

cs_images = [contrast_stretching(gray) for gray in gray_images]

# C. CLAHE (Contrast Limited Adaptive Histogram Equalization)
clahe = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8, 8))
clahe_images = [clahe.apply(gray) for gray in gray_images]
```

```
print("Proses Grayscale dan ketiga metode Enhancement telah selesai  
dilakukan untuk seluruh citra.")
```

Output:

```
Proses Grayscale dan ketiga metode Enhancement telah selesai  
dilakukan untuk seluruh citra.
```

Output hanya pesan konfirmasi bahwa HE, Contrast Stretching, dan CLAHE selesai diterapkan pada seluruh citra. Ketiganya sama-sama memperbaiki kontras tetapi dengan cara berbeda. HE meratakan distribusi histogram secara global, Contrast Stretching meregangkan rentang nilai piksel dari min-max ke 0-255, dan CLAHE memperbaiki kontras per blok 8×8 dengan batas penguatan (clipLimit=2.0) agar noise tidak berlebihan.

3. Visualisasi Hasil Perbandingan (Sampel 3 Gambar)

```
sample_indices = [0, 1, 2] # Mengambil 3 sampel citra pertama

for idx in sample_indices:
    plt.figure(figsize=(15, 10))

    # 1. Original (RGB)
    plt.subplot(1, 5, 1)
    plt.imshow(cv2.cvtColor(images[idx], cv2.COLOR_BGR2RGB))
    plt.title(f"Original Low-Light\n({names[idx]})")
    plt.axis('off')

    # 2. Grayscale
    plt.subplot(1, 5, 2)
    plt.imshow(gray_images[idx], cmap='gray')
    plt.title("Grayscale")
    plt.axis('off')

    # 3. Histogram Equalization
    plt.subplot(1, 5, 3)
    plt.imshow(he_images[idx], cmap='gray')
    plt.title("Histogram Equalization")
    plt.axis('off')
```

```

# 4. Contrast Stretching
plt.subplot(1, 5, 4)
plt.imshow(cs_images[idx], cmap='gray')
plt.title("Contrast Stretching")
plt.axis('off')

# 5. CLAHE
plt.subplot(1, 5, 5)
plt.imshow(clahe_images[idx], cmap='gray')
plt.title("CLAHE")
plt.axis('off')

plt.tight_layout()
plt.show()

```

Output:



Tiga figure dihasilkan, masing-masing berisi lima panel: original, grayscale, HE, contrast stretching, dan CLAHE untuk satu citra. Citra original dan grayscale tampak sangat gelap sehingga detailnya hampir tidak terlihat. Hasil enhancement seharusnya tampak lebih terang dengan detail objek lebih jelas, dan tiap metode punya karakter berbeda (misalnya HE cenderung paling agresif). Visualisasi ini memberi gambaran kualitatif sebelum perbandingan dilakukan dengan angka.

GAUSSIAN FILTER, MSE, PSNR

1. Konfigurasi dan fungsi (sesuai kesepakatan nama fungsi)

```
FILTER_METHOD = "gaussian"
KSIZE = 3

def apply_filter(img, method="median", ksize=3):
    """Filter citra uint8. method: 'median' atau 'gaussian'. ksize
    harus ganjil."""
    if ksize % 2 == 0 or ksize < 1:
        raise ValueError("ksize harus bilangan ganjil positif")
    method = method.lower()
    if method == "median":
        out = cv2.medianBlur(img, ksize)
    elif method == "gaussian":
        out = cv2.GaussianBlur(img, (ksize, ksize), 0) # sigma
        # sigma dihitung otomatis dari ksize
    else:
        raise ValueError("method harus 'median' atau 'gaussian'")
    return out.astype(np.uint8)

def mse(a, b):
    """Mean Squared Error antara dua citra berukuran sama."""
    if a.shape != b.shape:
        raise ValueError(f"Ukuran berbeda: {a.shape} vs {b.shape}")
    diff = a.astype(np.float64) - b.astype(np.float64)
    return float(np.mean(diff ** 2))

def psnr(a, b, max_val=255.0):
    """Peak Signal-to-Noise Ratio (dB). Bernilai inf jika kedua citra
    identik."""
    err = mse(a, b)
    if err == 0:
        return float("inf")
    return float(10 * np.log10((max_val ** 2) / err))

# Uji cepat: hasil fungsi manual dibandingkan dengan cv2.PSNR
_a = gray_images[0]
_b = apply_filter(_a, FILTER_METHOD, KSIZE)
print(f"Uji -> MSE = {mse(_a, _b):.4f} | PSNR manual = {psnr(_a,
_b):.4f} dB | cv2.PSNR = {cv2.PSNR(_a, _b):.4f} dB")
```

```
print(f"Filter dipakai: {FILTER_METHOD}, ksize = {KSIZE}")
```

Output:

```
Uji -> MSE = 1.7160 | PSNR manual = 45.7855 dB | cv2.PSNR = 45.7855 dB
Filter dipakai: gaussian, ksize = 3
```

Uji menghasilkan MSE = 1.7160 dan PSNR = 45.7855 dB, dan nilai PSNR dari fungsi manual sama persis dengan cv2.PSNR. Ini membuktikan fungsi mse() dan psnr() buatan kelompok sudah benar. PSNR setinggi ini wajar karena yang dibandingkan adalah citra sebelum dan sesudah blur Gaussian ringan (k=3) pada gambar yang sama, sehingga perbedaannya sangat kecil. Ini bukan perbandingan dengan citra referensi.

2. Load citra referensi (normal-light) dari folder our485/high, nama file sama

```
def high_path_from_low(low_path):
    return os.path.join(os.path.dirname(os.path.dirname(low_path)),
                        "high", os.path.basename(low_path))

ref_paths = [high_path_from_low(p) for p in paths]
missing = [p for p in ref_paths if not os.path.exists(p)]
assert not missing, f"Citra referensi tidak ditemukan: {missing[:3]}"

ref_images = [cv2.resize(cv2.imread(p), IMG_SIZE,
                        interpolation=cv2.INTER_AREA) for p in ref_paths]
ref_gray = [cv2.cvtColor(img, cv2.COLOR_BGR2GRAY) for img in
            ref_images]

print("Jumlah citra referensi:", len(ref_gray))
print("Shape referensi      :", ref_gray[0].shape, "| sama dengan",
      "citra uji:", ref_gray[0].shape == gray_images[0].shape)
```

Output:

```
Jumlah citra referensi: 25
Shape referensi      : (400, 600) | sama dengan citra uji: True
```

Sebanyak 25 citra referensi dari folder high berhasil dimuat, dengan nama file sama dengan pasangan low-light-nya. Output True pada pengecekan shape menandakan ukurannya identik dengan citra uji, yang merupakan syarat agar MSE dan PSNR bisa dihitung. Pengecekan assert juga memastikan tidak ada file referensi yang hilang.

3. Terapkan filter ke semua citra hasil Section 2

```
enhanced_images = {
    "Grayscale (tanpa enhancement)": gray_images,
    "Histogram Equalization": he_images,
    "Contrast Stretching": cs_images,
    "CLAHE": clahe_images,
}

filtered_images = {
    name: [apply_filter(img, FILTER_METHOD, KSIZE) for img in imgs]
    for name, imgs in enhanced_images.items()
}

print(f"Filter {FILTER_METHOD} (ksize={KSIZE}) diterapkan ke
{len(filtered_images)} kelompok citra x {len(gray_images)} citra.")
```

Output:

```
Filter gaussian (ksize=3) diterapkan ke 4 kelompok citra x 25 citra.
```

Output hanya konfirmasi bahwa filter Gaussian ($k=3$) diterapkan pada 4 kelompok citra $\times$ 25 citra, yaitu 100 citra hasil filter. Kelompoknya adalah Grayscale, HE, Contrast Stretching, dan CLAHE. Filter Gaussian dipakai untuk meredam noise yang mungkin ikut menguat saat kontras ditingkatkan.

4. Hitung MSE dan PSNR per citra (sebelum dan sesudah filter), terhadap referensi

```
rows = []
for method_name in enhanced_images:
    for i in range(len(names)):
        before = enhanced_images[method_name][i]
        after = filtered_images[method_name][i]
        ref = ref_gray[i]
```

```

rows.append({
    "citra": names[i],
    "metode": method_name,
    "MSE_sebelum_filter": mse(before, ref),
    "PSNR_sebelum_filter": psnr(before, ref),
    "MSE_sesudah_filter": mse(after, ref),
    "PSNR_sesudah_filter": psnr(after, ref),
})

df_metrics = pd.DataFrame(rows)

print("Contoh hasil per citra (5 baris pertama):")
display(df_metrics.head().round(2))

```

Output:

Contoh hasil per citra (5 baris pertama):						
	citra	metode	MSE_sebelum_filter	PSNR_sebelum_filter	MSE_sesudah_filter	PSNR_sesudah_filter
0	551.png	Grayscale (tanpa enhancement)	16925.16	5.85	16927.70	5.84
1	261.png	Grayscale (tanpa enhancement)	16357.68	5.99	16361.44	5.99
2	649.png	Grayscale (tanpa enhancement)	15219.92	6.31	15201.51	6.31
3	578.png	Grayscale (tanpa enhancement)	9012.34	8.58	9009.04	8.58
4	655.png	Grayscale (tanpa enhancement)	14155.98	6.62	14153.76	6.62

Kelima baris yang tampil semuanya dari metode Grayscale, dengan MSE sangat besar (sekitar 9.000-17.000) dan PSNR sangat rendah (5,85-8,58 dB). Artinya citra gelap sangat berbeda dari citra referensi yang terang. Nilai sebelum dan sesudah filter nyaris sama, bahkan pada citra 551.png MSE sedikit naik (16925 → 16927), sehingga filter tidak membantu mendekatkan citra gelap ke referensi. Ini wajar karena masalah utamanya adalah kecerahan, bukan noise.

5. Tabel rata-rata MSE dan PSNR per metode

```

order = list(enhanced_images.keys())
avg_table = (df_metrics.drop(columns="citra")
              .groupby("metode", sort=False).mean()
              .reindex(order))
avg_table["Selisih_PSNR (dB)"] = avg_table["PSNR_sesudah_filter"] -
avg_table["PSNR_sebelum_filter"]
avg_table = avg_table.round(2)
avg_table.index.name = f"Metode (filter {FILTER_METHOD}, k={KSIZE},

```

```

n={len(names)} ) "

print(f"TABEL RATA-RATA MSE & PSNR terhadap citra referensi
normal-light ({len(names)} citra)")
display(avg_table)

best = avg_table["PSNR_sesudah_filter"].idxmax()
print(f"PSNR rata-rata tertinggi setelah filter: {best}
({avg_table.loc[best, 'PSNR_sesudah_filter']:.2f} dB)")

```

Output:

TABEL RATA-RATA MSE & PSNR terhadap citra referensi normal-light (25 citra)					
	MSE_sebelum_filter	PSNR_sebelum_filter	MSE_sesudah_filter	PSNR_sesudah_filter	Selisih_PSNR (dB)
Metode (filter gaussian, k=3, n=25)					
Grayscale (tanpa enhancement)	12594.83	7.62	12598.81	7.62	-0.00
Histogram Equalization	2223.47	15.55	1887.04	16.45	0.89
Contrast Stretching	5816.00	12.58	5789.47	12.71	0.13
CLAHE	9017.82	9.28	9022.39	9.28	-0.00
PSNR rata-rata tertinggi setelah filter: Histogram Equalization (16.45 dB)					

Histogram Equalization memberi hasil terbaik: PSNR naik dari 15,55 ke 16,45 dB dan MSE turun dari 2223 ke 1887 setelah filter. Contrast Stretching di posisi kedua (12,58 → 12,71 dB), sedangkan CLAHE (9,28 dB) dan Grayscale (7,62 dB) paling jauh dari referensi. Selisih PSNR dari filter hanya berarti pada HE (+0,89 dB), sedangkan pada metode lain mendekati nol. Pemilihan HE sebagai metode terbaik ini dipakai lagi di Section 4 lewat variabel best.

6. Visualisasi: sebelum vs sesudah filter (sampel citra pertama) + referensi

```

idx = 0
fig, axes = plt.subplots(2, 5, figsize=(20, 7))

for col, method_name in enumerate(order):
    before = enhanced_images[method_name][idx]
    after = filtered_images[method_name][idx]
    # vmin/vmax dikunci 0-255 agar matplotlib tidak menormalisasi
    kecerahan otomatis
    axes[0, col].imshow(before, cmap="gray", vmin=0, vmax=255)
    axes[0, col].set_title(f"{method_name}\nPSNR {psnr(before,
ref_gray[idx]):.2f} dB", fontsize=10)
    axes[1, col].imshow(after, cmap="gray", vmin=0, vmax=255)
    axes[1, col].set_title(f"+ {FILTER_METHOD} k={KSIZE}\nPSNR

```

```

{psnr(after, ref_gray[idx]):.2f} dB", fontsize=10)

axes[0, 4].imshow(ref_gray[idx], cmap="gray", vmin=0, vmax=255)
axes[0, 4].set_title("Referensi (normal-light)", fontsize=10)
axes[1, 4].axis("off")
for ax in axes.ravel():
    ax.set_xticks([]); ax.set_yticks([])

plt.suptitle(f"Sebelum (atas) vs sesudah filter (bawah) - {names[idx]}", fontsize=13)
plt.tight_layout()
plt.show()

```

Output:




Figure berukuran 2×5 berisi baris atas (sebelum filter) dan baris bawah (sesudah filter) untuk citra 551.png, ditambah satu panel citra referensi. Judul tiap panel memuat nilai PSNR sehingga angka dan tampilan visual bisa dibandingkan sekaligus. Pengaturan `vmin=0`, `vmax=255` membuat kecerahan yang tampil apa adanya, tanpa dinormalisasi otomatis oleh matplotlib, sehingga perbandingannya adil.

7. Grafik rata-rata PSNR per metode

```

x = np.arange(len(order))
w = 0.38
fig, ax = plt.subplots(figsize=(10, 4.5))
b1 = ax.bar(x - w/2, avg_table["PSNR_sebelum_filter"], w,
label="Sebelum filter", color="#9aa5b1")
b2 = ax.bar(x + w/2, avg_table["PSNR_sesudah_filter"], w,
label=f"Sesudah filter {FILTER_METHOD} (k={KSIZE})", color="#2f6db5")


```

```

ax.bar_label(b1, fmt="%.2f", fontsize=9)
ax.bar_label(b2, fmt="%.2f", fontsize=9)
ax.set_xticks(x)
ax.set_xticklabels([m.replace(" (tanpa enhancement)", "") for m in
order])
ax.set_ylabel("PSNR rata-rata (dB)")
ax.set_title(f"Rata-rata PSNR terhadap citra referensi ({len(names)}
citra)")
ax.legend()
ax.spines[["top", "right"]].set_visible(False)
plt.tight_layout()
plt.show()

```

Output:



Grafik batang menampilkan PSNR rata-rata sebelum (abu-abu) dan sesudah filter (biru) untuk tiap metode, lengkap dengan label angka. Grafik ini merangkum tabel Cell 13 secara visual: HE paling tinggi, Grayscale paling rendah. Batang abu-abu dan biru yang hampir sama tinggi pada tiga metode menunjukkan pengaruh filter kecil, kecuali pada HE.

8. Pengaruh ukuran kernel terhadap PSNR rata-rata

```

ksize_rows = []
for k in [3, 5, 7]:
    for method_name, imgs in enhanced_images.items():
        vals = [psnr(apply_filter(img, FILTER_METHOD, k), ref) for
img, ref in zip(imgs, ref_gray)]
        ksize_rows.append({"metode": method_name, "ksize": k,

```

```

"PSNR_rata2": np.mean(vals))

ksize_table = (pd.DataFrame(ksize_rows)
                .pivot(index="metode", columns="ksize",
values="PSNR_rata2")
                .reindex(order).round(2))
ksize_table.columns = [f"PSNR k={k} (dB)" for k in
ksize_table.columns]
print(f"PSNR rata-rata untuk beberapa ukuran kernel (filter
{FILTER_METHOD}) ")
display(ksize_table)

```

Output:

PSNR rata-rata untuk beberapa ukuran kernel (filter gaussian)			
	PSNR k=3 (dB)	PSNR k=5 (dB)	PSNR k=7 (dB)
metode			
Grayscale (tanpa enhancement)	7.62	7.62	7.61
Histogram Equalization	16.45	16.53	16.55
Contrast Stretching	12.71	12.71	12.69
CLAHE	9.28	9.27	9.26

PSNR rata-rata hampir tidak berubah saat kernel diperbesar dari 3 ke 5 dan 7. HE naik tipis (16,45 $\rightarrow$ 16,53 $\rightarrow$ 16,55 dB), Contrast Stretching dan CLAHE sedikit turun atau stagnan. Perubahannya di bawah 0,1 dB pada hampir semua metode, jadi memperbesar kernel tidak memberi manfaat berarti. Kernel k=3 sudah cukup dan lebih efisien.

SIFT, ORB, MATCHING

1. Konfigurasi dan fungsi (sesuai kesepakatan nama fungsi)

```
ORB_NFEATURES = 5000 # batas maksimum keypoint ORB
RATIO = 0.75 # Lowe's ratio test
ACC_THRESH_PX = 5 # match akurat jika jarak posisi keypoint <= 5
# piksel

sift_detector = cv2.SIFT_create()
orb_detector = cv2.ORB_create(nfeatures=ORB_NFEATURES)

def extract_sift(img):
    """Ekstraksi fitur SIFT. Mengembalikan (keypoints, descriptors
float32 128-dim)."""
    return sift_detector.detectAndCompute(img, None)

def extract_orb(img):
    """Ekstraksi fitur ORB. Mengembalikan (keypoints, descriptors
uint8 32-byte)."""
    return orb_detector.detectAndCompute(img, None)

def match(desc1, desc2, method="sift", ratio=RATIO):
    """Brute-Force kNN matching + Lowe's ratio test. Mengembalikan
list match yang lolos."""
    if desc1 is None or desc2 is None or len(desc1) < 2 or len(desc2)
< 2:
        return []
    norm = cv2.NORM_L2 if method.lower() == "sift" else
cv2.NORM_HAMMING
    bf = cv2.BFMatcher(norm)
    good = []
    for pair in bf.knnMatch(desc1, desc2, k=2):
        if len(pair) == 2 and pair[0].distance < ratio *
pair[1].distance:
            good.append(pair[0])
    return good

EXTRACTORS = {"SIFT": extract_sift, "ORB": extract_orb}

def timed_extract(algo, img):
    """Ekstraksi + waktu (ms)."""
```

```

t0 = time.perf_counter()
kp, des = EXTRACTORS[algo](img)
return kp, des, (time.perf_counter() - t0) * 1000

# Pemanasan (warm-up) agar pemanggilan pertama tidak membuat waktu
bias
for algo in EXTRACTORS:
    EXTRACTORS[algo](gray_images[0])

_test = filtered_images[best][0] # citra hasil enhancement terbaik
(Section 3) + filter
kp_s, des_s = extract_sift(_test)
kp_o, des_o = extract_orb(_test)
print(f"Citra uji: {names[0]} ({best} + filter {FILTER_METHOD})")
print(f"Uji SIFT -> {len(kp_s)} keypoint, descriptor {None if des_s
is None else des_s.shape}, dtype {None if des_s is None else
des_s.dtype}")
print(f"Uji ORB -> {len(kp_o)} keypoint, descriptor {None if des_o
is None else des_o.shape}, dtype {None if des_o is None else
des_o.dtype}")

```

Output:

```

Citra uji: 551.png (Histogram Equalization + filter gaussian)
Uji SIFT -> 1251 keypoint, descriptor (1251, 128), dtype float32
Uji ORB -> 3329 keypoint, descriptor (3329, 32), dtype uint8

```

Pada citra 551.png (HE + Gaussian), SIFT menghasilkan 1251 keypoint dengan descriptor 128 dimensi bertipe float32. ORB menghasilkan 3329 keypoint dengan descriptor 32 byte bertipe uint8. Perbedaan tipe descriptor ini menjelaskan mengapa matching SIFT memakai jarak L2 sedangkan ORB memakai jarak Hamming. Proses warm-up sebelumnya dilakukan agar waktu pemanggilan pertama tidak membuat pengukuran waktu bias.

2. Ekstraksi fitur SIFT & ORB untuk semua citra: jumlah keypoint dan waktu

```

features = {} # features[algo, metode, i] = (kp, des)
ref_features = {} # ref_features[algo, i] = (kp, des)
feat_rows = []

for algo in EXTRACTORS:
    for i, ref in enumerate(ref_gray):

```

```

        kp, des, _ = timed_extract(algo, ref)
        ref_features[(algo, i)] = (kp, des)
    for method_name, imgs in filtered_images.items():
        for i, img in enumerate(imgs):
            kp, des, t_ms = timed_extract(algo, img)
            features[(algo, method_name, i)] = (kp, des)
            feat_rows.append({"algoritma": algo, "metode":
method_name, "citra": names[i],
                            "jumlah_keypoint": len(kp),
                            "waktu_ekstraksi_ms": t_ms})

df_feat = pd.DataFrame(feat_rows)
print(f"Ekstraksi selesai: {len(df_feat)} baris (2 algoritma x
{len(filtered_images)} metode x {len(names)} citra)")
display(df_feat.head().round(2))

```

Output:

Ekstraksi selesai: 200 baris (2 algoritma x 4 metode x 25 citra)					
	algoritma	metode	citra	jumlah_keypoint	waktu_ekstraksi_ms
0	SIFT	Grayscale (tanpa enhancement)	551.png	0	52.09
1	SIFT	Grayscale (tanpa enhancement)	261.png	1	60.05
2	SIFT	Grayscale (tanpa enhancement)	649.png	0	43.09
3	SIFT	Grayscale (tanpa enhancement)	578.png	0	43.92
4	SIFT	Grayscale (tanpa enhancement)	655.png	0	43.42

Terbentuk 200 baris data hasil $2 \text{ algoritma} \times 4 \text{ metode} \times 25 \text{ citra}$, dengan jumlah keypoint dan waktu ekstraksi per citra. Lima baris yang tampil (SIFT pada Grayscale) hanya punya 0-1 keypoint. Citra gelap tanpa enhancement hampir tidak punya kontras yang cukup bagi SIFT untuk mendeteksi titik fitur. Waktu ekstraksinya tetap sekitar 43-60 ms walau keypoint nyaris nol, karena SIFT tetap membangun scale-space terlebih dahulu.

3. Tabel rata-rata jumlah keypoint dan waktu ekstraksi

```

feat_avg = (df_feat.groupby(["metode", "algoritma"],
sort=False)[["jumlah_keypoint", "waktu_ekstraksi_ms"]]
            .mean().unstack("algoritma"))
feat_avg = feat_avg.reindex(order)
feat_avg.columns = [f"'Keypoint' if c == 'jumlah_keypoint' else

```

```
'Waktu (ms)'} {a}" for c, a in feat_avg.columns]
feat_avg = feat_avg[["Keypoint SIFT", "Keypoint ORB", "Waktu (ms)
SIFT", "Waktu (ms) ORB"]].round(2)
feat_avg.index.name = f"Metode (n={len(names)} citra)"

print("TABEL RATA-RATA JUMLAH KEYPOINT DAN WAKTU EKSTRAKSI PER
CITRA")
display(feat_avg)
```

Output:

TABEL RATA-RATA JUMLAH KEYPOINT DAN WAKTU EKSTRAKSI PER CITRA				
	Keypoint SIFT	Keypoint ORB	Waktu (ms) SIFT	Waktu (ms) ORB
Metode (n=25 citra)				
Grayscale (tanpa enhancement)	7.56	21.08	62.53	2.73
Histogram Equalization	2164.44	3416.20	239.07	16.19
Contrast Stretching	533.04	1072.44	75.16	7.74
CLAHE	179.96	382.88	56.15	4.77

HE menghasilkan keypoint terbanyak (SIFT 2164, ORB 3416), disusul Contrast Stretching, CLAHE, lalu Grayscale yang hanya 7-21 keypoint. Jumlah keypoint yang banyak datang dengan harga waktu ekstraksi yang lebih lama, terutama pada SIFT-HE yang mencapai 239 ms. ORB selalu jauh lebih cepat (2,7-16 ms) pada semua metode. Hasil ini menunjukkan enhancement kontras sangat menentukan jumlah fitur yang bisa dideteksi.

4. Visualisasi keypoint SIFT dan ORB (sampel citra pertama)

```
idx = 0
fig, axes = plt.subplots(2, len(order), figsize=(22, 8))

for col, method_name in enumerate(order):
    img = filtered_images[method_name][idx]
    for row, (algo, color) in enumerate([("SIFT", (0, 255, 0)),
    ("ORB", (255, 0, 0))]):
        kp, _ = features[(algo, method_name, idx)]
        vis = cv2.drawKeypoints(cv2.cvtColor(img,
        cv2.COLOR_GRAY2RGB), kp, None, color=color)
        axes[row, col].imshow(vis)
        axes[row, col].set_title(f"{algo} - {method_name}\n{n={len(kp)}}
```

```

keypoint", fontsize=10)
    axes[row, col].axis("off")

plt.suptitle(f"Keypoint SIFT (atas, hijau) dan ORB (bawah, merah) - {names[idx]}", fontsize=13)
plt.tight_layout()
plt.show()

```

Output:




Figure 2×4 menampilkan keypoint SIFT (hijau, baris atas) dan ORB (merah, baris bawah) pada empat metode untuk citra 551.png. Judul tiap panel mencantumkan jumlah keypoint-nya. Dari angka yang tersedia, panel HE seharusnya paling padat titiknya dan panel Grayscale nyaris kosong. Gambar ini memperlihatkan bahwa keypoint tidak muncul di area gelap tanpa tekstur dan terkonsentrasi pada area dengan kontras tinggi.

5. Feature matching: citra low-light hasil pemrosesan vs citra referensi normal-light

```

def match_accuracy(kp1, kp2, matches, thresh=ACC_THRESH_PX):
    """Jumlah match yang posisinya konsisten (pasangan LOL sejajar,
    jadi posisi seharusnya hampir sama)."""
    if not matches:
        return 0

    p1 = np.float32([kp1[m.queryIdx].pt for m in matches])
    p2 = np.float32([kp2[m.trainIdx].pt for m in matches])
    return int(np.sum(np.linalg.norm(p1 - p2, axis=1) <= thresh))

matches_cache = {}

```

```

match_rows = []
for algo in EXTRACTORS:
    for method_name in order:
        for i in range(len(names)):
            kp1, des1 = features[(algo, method_name, i)]
            kp2, des2 = ref_features[(algo, i)]
            t0 = time.perf_counter()
            good = match(des1, des2, algo)
            t_match = (time.perf_counter() - t0) * 1000
            n_acc = match_accuracy(kp1, kp2, good)
            matches_cache[(algo, method_name, i)] = good
            match_rows.append({"algoritma": algo, "metode":
method_name, "citra": names[i],
                                "good_matches": len(good),
                                "match_akurat": n_acc,
                                "akurasi_%": 100 * n_acc / len(good)
                                if good else 0.0,
                                "waktu_matching_ms": t_match})

df_match = pd.DataFrame(match_rows)
print(f"Matching selesai: {len(df_match)} pasangan citra")
display(df_match.head().round(2))

```

Output:

Matching selesai: 200 pasangan citra							
	algoritma	metode	citra	good_matches	match_akurat	akurasi_%	waktu_matching_ms
0	SIFT	Grayscale (tanpa enhancement)	551.png	0	0	0.0	0.0
1	SIFT	Grayscale (tanpa enhancement)	261.png	0	0	0.0	0.0
2	SIFT	Grayscale (tanpa enhancement)	649.png	0	0	0.0	0.0
3	SIFT	Grayscale (tanpa enhancement)	578.png	0	0	0.0	0.0
4	SIFT	Grayscale (tanpa enhancement)	655.png	0	0	0.0	0.0

Matching dilakukan pada 200 pasangan citra (hasil pemrosesan vs referensi normal-light) dengan Lowe's ratio test 0,75. Lima baris pertama bernilai 0 good matches, 0 match akurat, dan akurasi 0%, karena keypoints SIFT pada Grayscale terlalu sedikit untuk dicocokkan. Kolom match_akurat menghitung match yang posisinya berselisih ≤ 5 piksel, dengan asumsi pasangan citra LOL sejajar.

6. Tabel rata-rata hasil matching

```
grp = df_match.groupby(["metode", "algoritma"], sort=False)
match_avg = grp[["good_matches", "match_akurat",
"waktu_matching_ms"]].mean()
# Akurasi = total match akurat / total good matches (citra tanpa
match tidak dihitung 0%)
match_avg["akurasi_%"] = (100 * grp["match_akurat"].sum() /
grp["good_matches"].sum().replace(0, np.nan)).fillna(0)
match_avg = match_avg.unstack("algoritma").reindex(order)
label = {"good_matches": "Good matches", "match_akurat": "Match
akurat",
        "akurasi_%": "Akurasi (%)", "waktu_matching_ms": "Waktu
matching (ms)"}
match_avg.columns = [f"{label[c]} {a}" for c, a in match_avg.columns]
match_avg = match_avg[[f"{label[c]} {a}" for c in label for a in
["SIFT", "ORB"]]].round(2)
match_avg.index.name = f"Metode (n={len(names)} pasangan)"

print("TABEL RATA-RATA FEATURE MATCHING (low-light hasil pemrosesan
vs referensi normal-light)")
display(match_avg)
```

Output:

	Good matches SIFT	Good matches ORB	Match akurat SIFT	Match akurat ORB	Akurasi (%) SIFT	Akurasi (%) ORB	Waktu matching (ms) SIFT	Waktu matching (ms) ORB
Metode (n=25 pasangan)								
Grayscale (tanpa enhancement)	3.32	5.20	3.12	5.04	93.98	96.92	0.56	1.91
Histogram Equalization	353.40	986.64	310.52	947.60	87.87	96.04	74.18	270.11
Contrast Stretching	178.44	477.16	163.36	469.08	91.55	98.31	16.68	76.82
CLAHE	92.68	165.96	88.24	162.80	95.21	98.10	8.45	28.81

HE menghasilkan good matches terbanyak (SIFT 353, ORB 987), tetapi akurasi SIFT-nya justru paling rendah (87,87%). CLAHE punya akurasi SIFT tertinggi (95,21%) walau match-nya lebih sedikit. ORB akurasinya konsisten tinggi di semua metode (96-98%), dengan tertinggi pada Contrast Stretching (98,31%). Waktu matching naik tajam seiring jumlah keypoint, misalnya ORB-HE mencapai 270 ms. Akurasi 93-96% pada Grayscale berasal dari hanya 3-5 match per citra sehingga kurang bermakna.

7. Visualisasi matching SIFT vs ORB (sampel citra pertama, metode dengan PSNR terbaik di Section 3)


```
idx = 0
method_show = best    # metode dengan PSNR rata-rata tertinggi dari
                        Section 3
N_SHOW = 50           # tampilkan 50 match terbaik agar gambar tidak
                        terlalu padat

fig, axes = plt.subplots(2, 1, figsize=(16, 12))
for row, algo in enumerate(EXTRACTORS):
    kp1, _ = features[(algo, method_show, idx)]
    kp2, _ = ref_features[(algo, idx)]
    good = sorted(matches_cache[(algo, method_show, idx)], key=lambda
m: m.distance)
    vis = cv2.drawMatches(filtered_images[method_show][idx], kp1,
ref_gray[idx], kp2, good[:N_SHOW], None,

flags=cv2.DrawMatchesFlags_NOT_DRAW_SINGLE_POINTS)
    n_acc = match_accuracy(kp1, kp2, good)
    axes[row].imshow(vis)
    axes[row].set_title(f"{algo}: {len(good)} good matches, {n_acc}
akurat ")
    axes[row].text(0.5, 0.05, f"({100 * n_acc / len(good) if good else
0:.1f}%) - ditampilkan {min(N_SHOW, len(good))} terbaik",
                    fontsize=11)
    axes[row].axis("off")

plt.suptitle(f"Feature matching {method_show} + filter
{FILTER_METHOD} (kiri) vs referensi normal-light (kanan) -
{names[idx]}",
             fontsize=13)
plt.tight_layout()
plt.show()
```

Output:



Dua gambar ditampilkan: SIFT di atas dan ORB di bawah, masing-masing memperlihatkan 50 match terbaik antara citra HE + filter (kiri) dan referensi (kanan). Judul gambar memuat jumlah good matches, jumlah match akurat, dan persentasenya. Garis-garis penghubung diharapkan hampir horizontal dan sejajar, karena kedua citra memang berposisi sama. Garis yang miring tajam menandakan match yang salah.

8. Grafik perbandingan SIFT vs ORB per metode

```
metrics = [("Keypoint", feat_avg, "Rata-rata jumlah keypoint"),  
           ("Waktu (ms)", feat_avg, "Rata-rata waktu ekstraksi  
(ms)"),  
           ("Good matches", match_avg, "Rata-rata good matches"),  
           ("Akurasi (%)", match_avg, "Akurasi matching (%)")]  
x = np.arange(len(order))  
w = 0.38  
xlabel = [m.replace(" (tanpa enhancement)", "").replace("Histogram  
Equalization", "HE")  
          .replace("Contrast Stretching", "Contrast\nStretching")]
```

```


for m in order]

fig, axes = plt.subplots(2, 2, figsize=(14, 9))
for ax, (prefix, table, title) in zip(axes.ravel(), metrics):
    b1 = ax.bar(x - w/2, table[f"{prefix} SIFT"], w, label="SIFT",
color="#2f6db5")
    b2 = ax.bar(x + w/2, table[f"{prefix} ORB"], w, label="ORB",
color="#e07b39")
    ax.bar_label(b1, fmt="%.1f", fontsize=8)
    ax.bar_label(b2, fmt="%.1f", fontsize=8)
    ax.set_xticks(x)
    ax.set_xticklabels(xlabels, fontsize=9)
    ax.set_title(title)
    ax.spines[["top", "right"]].set_visible(False)
    ax.legend(fontsize=9)

plt.suptitle(f"Perbandingan SIFT vs ORB ({len(names)} citra, filter
{FILTER_METHOD} k={KSIZE})", fontsize=13)
plt.tight_layout()
plt.show()

```

Output:



Empat grafik batang membandingkan SIFT (biru) dan ORB (oranye) untuk rata-rata keypoint, waktu ekstraksi, good matches, dan akurasi di tiap metode. ORB lebih tinggi di keypoint, good matches, dan akurasi, serta jauh lebih rendah di waktu ekstraksi. Metode HE paling mencolok pada grafik keypoint dan waktu, sedangkan Grayscale hampir tidak terlihat batangnya. Satu tampilan ini cukup untuk membandingkan kedua algoritma di semua metode enhancement.

9. Ringkasan keseluruhan SIFT vs ORB (rata-rata semua metode dan citra)

```
summary = pd.DataFrame({
    "Rata-rata keypoint/citra":
df_feat.groupby("algoritma")["jumlah_keypoint"].mean(),
    "Rata-rata waktu ekstraksi (ms)":
df_feat.groupby("algoritma")["waktu_ekstraksi_ms"].mean(),
    "Waktu per 1000 keypoint (ms)":
df_feat.groupby("algoritma").apply(
        lambda d: 1000 * d["waktu_ekstraksi_ms"].sum() /
max(d["jumlah_keypoint"].sum(), 1)),
    "Rata-rata good matches":
df_match.groupby("algoritma")["good_matches"].mean(),
    "Akurasi matching (%)": 100 *
df_match.groupby("algoritma")["match_akurat"].sum()
/
df_match.groupby("algoritma")["good_matches"].sum().replace(0,
np.nan),
    "Rata-rata waktu matching (ms)":
df_match.groupby("algoritma")["waktu_matching_ms"].mean(),
}).reindex(["SIFT", "ORB"]).round(2)

print("RINGKASAN PERBANDINGAN SIFT vs ORB")
display(summary)

faster = summary["Rata-rata waktu ekstraksi (ms)"].idxmin()
ratio_speed = summary["Rata-rata waktu ekstraksi (ms)"].max() /
summary["Rata-rata waktu ekstraksi (ms)"].min()
print(f"- Ekstraksi lebih cepat : {faster} (sekitar
{ratio_speed:.1f}x lebih cepat)")
print(f"- Keypoint lebih banyak : {summary['Rata-rata
keypoint/citra'].idxmax()}")
print(f"- Akurasi matching lebih tinggi : {summary['Akurasi matching
(%)'].idxmax()}")
```

Output:

RINGKASAN PERBANDINGAN SIFT vs ORB

/tmp/ipykernel_849/2187856944.py:5: DeprecationWarning: DataFrameGroupBy.apply operated on the grouping columns. This behavior is deprecated, and in a future version of pandas the grouping columns will be excluded from the operation. Either pass `include\_groups=False` to exclude the groupings or explicitly select the grouping columns after groupby to silence this warning.

"Waktu per 1000 keypoint (ms)": df_feat.groupby("algoritma").apply(

	Rata-rata keypoint/citra	Rata-rata waktu ekstraksi (ms)	Waktu per 1000 keypoint (ms)	Rata-rata good matches	Akurasi matching (%)	Rata-rata waktu matching (ms)
algoritma						
SIFT	721.25	108.23	150.06	156.96	90.03	24.97
ORB	1223.15	7.85	6.42	408.74	96.91	94.41

- Ekstraksi lebih cepat : ORB (sekitar 13.8x lebih cepat)
- Keypoint lebih banyak : ORB
- Akurasi matching lebih tinggi : ORB

ORB unggul di sebagian besar aspek: keypoint 1223 vs 721, ekstraksi 7,85 vs 108,23 ms (sekitar 13,8× lebih cepat), good matches 409 vs 157, dan akurasi 96,91% vs 90,03%. Pengecualiannya adalah waktu matching, di mana SIFT lebih cepat (24,97 vs 94,41 ms) karena ORB harus mencocokkan keypoint yang jauh lebih banyak. Waktu per 1000 keypoint (SIFT 150 ms vs ORB 6,4 ms) menunjukkan ORB lebih efisien per fitur. Peringatan DeprecationWarning hanya terkait versi pandas dan tidak memengaruhi hasil.

Ringkasan Hasil :

Percobaan ini menggunakan 25 citra low-light yang dipilih secara acak (seed 12) dari LOL Dataset yang berisi 485 citra. Setiap citra diubah ukurannya menjadi 600×400 piksel dan dikonversi ke grayscale. Citra kemudian diperbaiki kontrasnya dengan tiga metode, yaitu Histogram Equalization (HE), Contrast Stretching, dan CLAHE, lalu dihaluskan dengan filter Gaussian berukuran kernel 3. Seluruh hasilnya dibandingkan dengan citra normal-light pasangannya sebagai referensi.

Dari sisi kualitas citra, Histogram Equalization memberikan hasil terbaik. Setelah difilter, HE mencapai PSNR rata-rata 16,45 dB dengan MSE 1.887,04, naik dari 15,55 dB sebelum difilter. Contrast Stretching berada di posisi kedua dengan PSNR 12,71 dB. CLAHE hanya mencapai 9,28 dB, sedangkan grayscale tanpa enhancement paling rendah dengan 7,62 dB dan MSE 12.598,81. Filter Gaussian hanya memberi peningkatan berarti pada HE (sekitar 0,89 dB), sementara pada metode lain perubahannya mendekati nol. Memperbesar kernel dari 3 ke 5 dan 7 juga hampir tidak berpengaruh, dengan selisih PSNR kurang dari 0,1 dB.

Pada tahap ekstraksi fitur, ORB menghasilkan rata-rata 1.223 keypoint per citra, lebih banyak daripada SIFT yang hanya 721. ORB juga jauh lebih cepat, dengan waktu ekstraksi rata-rata 7,85 ms dibanding 108,23 ms pada SIFT, atau sekitar 13,8 kali lebih cepat. Jika dihitung per 1000 keypoint, SIFT membutuhkan sekitar 150 ms sedangkan ORB hanya 6,4 ms.

Pada tahap feature matching terhadap citra referensi, ORB menghasilkan rata-rata 408,74 good matches dibanding 156,96 pada SIFT. Akurasi matching ORB (96,91%) juga lebih tinggi daripada SIFT (90,03%). Namun waktu matching ORB justru lebih lama, yaitu 94,41 ms dibanding 24,97 ms pada SIFT, karena ORB harus mencocokkan keypoint dalam jumlah yang jauh lebih banyak.

Jenis enhancement sangat memengaruhi jumlah fitur yang terdeteksi. Grayscale tanpa enhancement hampir tidak menghasilkan keypoint (SIFT sekitar 7,6 dan ORB sekitar 21 per citra), sehingga hampir tidak ada match. HE menghasilkan fitur terbanyak, yaitu SIFT 2.164 keypoint dengan 353 good matches dan ORB 3.416 keypoint dengan 987 good matches, tetapi dengan waktu proses paling lama. Contrast Stretching berada di tengah. CLAHE menghasilkan fitur paling sedikit di antara ketiganya, namun memiliki akurasi SIFT tertinggi (95,21%).

Kesimpulan :

Pertama, enhancement kontras wajib dilakukan sebelum ekstraksi fitur pada citra low-light. Tanpa perbaikan kontras, SIFT maupun ORB hampir tidak mampu mendeteksi keypoint, sedangkan setelah enhancement jumlahnya meningkat ratusan kali lipat.

Kedua, Histogram Equalization adalah metode terbaik dalam percobaan ini. HE memiliki PSNR tertinggi, MSE terendah, serta keypoint dan good matches terbanyak. Kekurangannya adalah waktu komputasi yang lebih lama dibanding metode lain.

Ketiga, filter Gaussian hanya berdampak kecil. Manfaatnya terbatas pada HE, dan karena pengaruh ukuran kernel sangat kecil, kernel 3×3 sudah cukup dan lebih efisien.

Keempat, ORB lebih unggul dalam ekstraksi fitur. Algoritma ini menghasilkan lebih banyak keypoint dengan waktu jauh lebih singkat, serta akurasi matching yang lebih tinggi, sehingga cocok untuk aplikasi yang membutuhkan kecepatan atau pemrosesan real-time. Sebaliknya, SIFT unggul dalam kecepatan matching karena jumlah fiturnya lebih sedikit tetapi descriptor-nya lebih kaya (128 dimensi float). Secara teori SIFT juga lebih tahan terhadap perubahan skala dan rotasi, tetapi hal ini tidak diuji dalam notebook.

Kelima, kombinasi yang paling menjanjikan adalah HE dengan ORB. Kombinasi ini menghasilkan fitur terbanyak, akurasi matching tinggi (sekitar 96%), dan ekstraksi yang cepat. Jika prioritasnya adalah akurasi pada jumlah fitur yang lebih sedikit, CLAHE dengan SIFT atau Contrast Stretching dengan ORB (akurasi 98,31%) dapat menjadi alternatif.

LAMPIRAN

No.	Nama	Link
1.	Link Dataset	https://www.kaggle.com/datasets/soumikrakshit/lol-dataset
2.	Link Google Colab	https://colab.research.google.com/drive/1YyfRRzWv5ZJBU-GMeLLDfDJSLhAuux9h?usp=sharing
3	Link Github	https://github.com/mferdian/UTS-Computer-Vision-Kelompok-12